

Voici un résumé du contenu de ce fichier (qui est un notebook Jupyter structuré pour un projet d'apprentissage automatique) :

1. Objectif du projet

- Le projet vise à développer un modèle de bout en bout en utilisant la **régression linéaire** pour prédire le prix des maisons à Boston (*Boston House Price Prediction Project*).
- Il couvre plusieurs étapes clés : la visualisation approfondie, l'ingénierie des caractéristiques (*feature engineering*) et la sélection de variables basée sur leur corrélation.

2. Importation et préparation des données

- Les bibliothèques standards de la science de données en Python sont chargées (`numpy`, `pandas`, `plotly`, `seaborn`, `matplotlib`).
- Les données sont lues à partir d'un fichier nommé `BostonHousing.csv`.
- Une variable cible nommée `SalePrice` est créée en dupliquant la colonne `medv` (qui représente la valeur médiane des logements).
- Des vérifications de base sont effectuées pour observer la structure globale (dimensions avec `shape`, types de données et valeurs manquantes avec `info` et `isnull`, statistiques descriptives avec `describe`).

3. Analyse Exploratoire des Données (EDA)

- **Visualisations** : Le code génère des graphiques de paires (*pairplot*) pour étudier les relations entre toutes les variables, ainsi que des diagrammes de dispersion (*scatter plots*) ciblés pour analyser l'impact du taux de criminalité (`crim`) et de l'âge des logements (`age`) sur le prix.
- **Étude de la distribution** : L'asymétrie (*skewness*) et l'aplatissement (*kurtosis*) de la variable cible `SalePrice` sont analysés. Une courbe normale et un graphique Q-Q plot sont utilisés pour évaluer sa normalité.
- **Transformation** : Une transformation logarithmique (`np.log1p`) est appliquée sur `SalePrice` afin de rendre sa distribution plus normale et améliorer l'efficacité du modèle linéaire.

4. Corrélation et sélection des caractéristiques

- Une carte de chaleur (*heatmap*) de la matrice de corrélation est tracée.
- Un filtre est appliqué pour sélectionner uniquement les variables explicatives qui ont une valeur absolue de corrélation supérieure à 0.2 avec le prix de vente (`SalePrice`).

5. Construction et évaluation du modèle

- Le jeu de données est séparé en fonctionnalités (X) et cible (y), puis divisé en données d'entraînement (80 %) et de test (20 %) avec `train_test_split`.
- Un modèle de **Régression Linéaire** de *scikit-learn* est entraîné sur le jeu d'entraînement.
- Le modèle réalise ensuite des prédictions sur les données de test. Le fichier inclut une comparaison textuelle entre une valeur réelle et sa prédiction, puis calcule la performance finale du modèle à l'aide de la racine de l'erreur quadratique moyenne (**RMSE**).